



Fundação Getúlio Vargas
Laboratório de Políticas Públicas

Relatório Final de Pesquisa

Entre Elogios e Críticas

Classificação Automatizada de Notícias sobre o Programa
Segurança Presente com Modelos de Linguagem

Autoras e autores

Maria Eduarda Mesquita Magalhães
Bianca Fialho Salgado Djelberian
Maria Teresa Mendes Madureira
Kayo Francisco da Silva
Sarah Ribeiro Lattouf

Professora

[Katia Aiko Nishiyama Alves]

Rio de Janeiro
Junho de 2026

Resumo

Este relatório apresenta a versão final do projeto de análise automatizada de notícias sobre o programa Segurança Presente, desenvolvido a partir do pré-projeto *LLM Segurança Presente*. O objetivo foi aplicar um modelo de linguagem de grande escala para classificar notícias segundo a percepção retratada na cobertura jornalística e, simultaneamente, identificar o evento ou tema factual central de cada notícia. A pipeline final parte de um arquivo JSON já coletado, remove duplicatas nas análises agregadas, classifica sentimento e evento em uma única chamada ao LLM, gera tabelas analíticas, gráficos temporais e rankings de eventos mais positivamente e negativamente retratados. Ao final, foram processadas 863 linhas brutas de notícias e produzida uma base final com 852 notícias únicas.

Sumário

1	Introdução	3
2	Objetivos	3
2.1	Objetivo geral	3
2.2	Objetivos específicos	3
3	Dados	3
3.1	Cobertura temporal	4
3.2	Tamanho da base	4
4	Pipeline implementada	4
4.1	Preparação da entrada	4
4.2	Fase 1: classificação LLM	5
4.3	Prompt único	6
4.4	Classes de sentimento	7
4.5	Grau de ambiguidade	7
4.6	Fase 2: gráficos e tabelas	8
4.7	Fase 3: ranking de eventos	8
5	Deduplicação	9
6	Resultados gerais de sentimento	9
7	Ambiguidade da classificação	10
8	Rankings de eventos	10
8.1	Eventos mais amados	10
8.2	Eventos mais odiados	11
9	Gráficos produzidos	11
9.1	Distribuição geral	12
9.2	Evolução temporal	13
9.3	Ambiguidade e fontes	14
10	Produtos finais gerados	15
10.1	Tabelas	15
10.2	Procedimento computacional	16
11	Discussão	16
12	Limitações	16
13	Conclusão	17

1 Introdução

O pré-projeto que orientou este trabalho propôs investigar como modelos de linguagem de grande escala, ou LLMs, poderiam ser usados para classificar notícias sobre políticas públicas de segurança de acordo com a percepção pública retratada pela mídia. A motivação central era lidar com um volume de notícias grande demais para classificação manual sistemática, especialmente em um tema sensível como segurança pública no Rio de Janeiro.

Na versão final, o recorte foi concentrado no programa Segurança Presente. O trabalho não mede diretamente a opinião da população, como faria uma pesquisa amostral. O objeto analisado é a cobertura jornalística online: isto é, como as notícias disponíveis retratam o programa, suas ações, eventos associados, controvérsias, operações, inaugurações, decisões administrativas e resultados.

A pergunta operacional que guiou a implementação foi:

Como uma LLM pode classificar, em escala, notícias sobre o Segurança Presente quanto ao sentimento retratado e quanto ao evento factual central de cada notícia?

2 Objetivos

2.1 Objetivo geral

Construir uma pipeline reprodutível que, a partir de um JSON de notícias já coletadas, classifique cada notícia quanto ao sentimento retratado sobre o Segurança Presente e identifique o evento factual central de cada texto.

2.2 Objetivos específicos

- Ler as notícias a partir de um único arquivo JSON de entrada.
- Evitar duplicidade nas análises finais.
- Classificar cada notícia em uma escala de sentimento.
- Extrair, por LLM, o evento ou tema factual principal de cada notícia.
- Gerar um CSV com uma linha por notícia classificada.
- Gerar tabelas agregadas de sentimento, ambiguidade, fonte e tempo.
- Gerar gráficos de evolução temporal e distribuição dos sentimentos.
- Produzir rankings de eventos mais positivamente e negativamente retratados.

3 Dados

A base de entrada usada pela pipeline final é:

```
src/dados_entrada/seguranca_presente_artigos.json
```

O arquivo contém notícias associadas ao Segurança Presente. A pipeline atual não depende mais de caminhos duplicados, snapshots antigos ou bases alternativas. O repositório foi simplificado para partir diretamente desse JSON.

3.1 Cobertura temporal

As notícias com data válida cobrem o período entre:

- **31 de maio de 2016**
- **11 de junho de 2026**

Foram identificadas 827 notícias com data válida na base final deduplicada. Notícias sem data válida continuam podendo entrar nas análises não temporais, mas são excluídas dos gráficos de série temporal.

3.2 Tamanho da base

Etapa	Quantidade
Linhas brutas classificadas pelo LLM	863
Notícias únicas na base final	852
Duplicatas no CSV final	0
Notícias com data válida na base final	827

Tabela 1: Tamanho da base processada.

4 Pipeline implementada

A pipeline principal foi organizada como um fluxo sequencial. O objetivo foi transformar uma base bruta de notícias em um conjunto de produtos analíticos: uma tabela com a classificação individual de cada notícia, estatísticas agregadas, gráficos de evolução temporal e rankings de eventos. O procedimento completo pode ser resumido em três grandes fases:

1. Classificação das notícias com LLM.
2. Geração de tabelas e gráficos de sentimento.
3. Geração do ranking de eventos.

4.1 Preparação da entrada

Antes da classificação, a base de notícias é lida a partir de um único arquivo JSON. Cada registro bruto é convertido em uma observação padronizada, preservando as informações necessárias para análise posterior: identificador da notícia, identificador do artigo, título, fonte, data de publicação, resumo, texto integral quando disponível e metadados de origem.

Essa padronização é importante porque nem todos os registros chegam exatamente com o mesmo nível de informação. Algumas notícias possuem texto completo; outras

têm principalmente título e resumo. Por isso, o procedimento monta um campo textual composto, juntando título, resumo e corpo da notícia. Esse texto combinado é o que será enviado ao modelo de linguagem para classificação.

Também é preservado um identificador interno da linha original. Esse identificador permite manter o arquivo bruto de classificação com o mesmo número de linhas da base de entrada, mesmo quando há notícias repetidas. A remoção de duplicatas acontece apenas nas etapas analíticas finais.

4.2 Fase 1: classificação LLM

A primeira fase envia cada notícia para um modelo de linguagem da OpenAI. O modelo usado na configuração final é:

`gpt-4o-mini`

A chave de API é lida do arquivo `.env`, por meio da variável:

`OPENAI_API_KEY`

Para cada notícia, o procedimento executa os seguintes passos:

1. reúne título, resumo e texto bruto em uma única entrada textual;
2. limita o tamanho do texto enviado para evitar excesso de tokens;
3. insere a notícia no prompt de classificação;
4. envia a requisição ao modelo com temperatura zero, buscando respostas mais estáveis;
5. exige uma resposta em formato JSON;
6. interpreta o JSON retornado;
7. normaliza o rótulo de sentimento e o grau de ambiguidade;
8. grava a linha classificada no arquivo de saída.

O sistema também foi preparado para retomar execuções interrompidas. Se uma notícia já havia sido classificada anteriormente e possui rótulo de sentimento e evento preenchidos, ela não é enviada novamente ao modelo. Isso reduz custo, tempo de execução e risco de inconsistência entre rodadas.

O resultado bruto da classificação é salvo em:

`tabelas/llm_labels.csv`

Esse arquivo possui 863 linhas, uma para cada registro original classificado.

4.3 Prompt único

Uma decisão importante da versão final foi usar um único prompt para duas tarefas:

1. Classificar o sentimento da notícia.
2. Identificar o evento factual central da notícia.

O prompt foi mantido separado da lógica de execução para facilitar revisão metodológica. Ele orienta o modelo a retornar somente um JSON válido, com os seguintes campos principais:

- `label`
- `sentiment_score`
- `grau_ambiguidade`
- `reason_sentimento`
- `evento`
- `evento_chave`
- `tipo_evento`
- `local`
- `data_evento`
- `descricao_curta`
- `evidencia_sentimento`
- `evidencia_evento`

O desenho do prompt segue quatro princípios. Primeiro, o modelo deve analisar apenas o conteúdo da notícia, sem completar informações com conhecimento externo. Segundo, o sentimento deve se referir ao modo como o programa, sua gestão, seus agentes ou eventos associados são retratados, e não a uma avaliação genérica de segurança pública. Terceiro, crimes e prisões não são classificados automaticamente como negativos ou positivos: a notícia precisa associar o fato ao programa para que o sentimento seja atribuído. Quarto, o evento identificado deve ser factual e específico, evitando categorias amplas demais como “segurança pública” ou “policciamento”.

Essa escolha foi importante porque o objetivo final não era apenas contar sentimentos, mas também produzir um ranking de acontecimentos concretos. Assim, o modelo precisava separar eventos parecidos, mas distintos. Um show da Shakira e um show da Lady Gaga, por exemplo, são ambos eventos culturais em Copacabana, mas não são o mesmo evento analítico.

4.4 Classes de sentimento

O modelo foi instruído a escolher exatamente uma das seguintes classes:

- muito negativo
- negativo
- neutro
- positivo
- muito positivo
- n/a

O campo `sentiment_score` traduz essas classes para uma escala numérica:

Classe	Escore
muito negativo	-2
negativo	-1
neutro	0
positivo	1
muito positivo	2
n/a	nulo

Tabela 2: Conversão dos rótulos de sentimento em escore numérico.

Esse escore permite calcular médias por evento e construir rankings de eventos mais amados e mais odiados.

Na prática, essa escala transforma uma classificação textual em uma medida numérica simples. Com isso, é possível calcular a média de sentimento de um evento, comparar eventos entre si e ordenar os casos mais negativos e mais positivos. Notícias classificadas como `n/a` não entram no cálculo da média, porque não representam uma avaliação clara do programa ou do evento.

4.5 Grau de ambiguidade

Em vez de usar uma métrica abstrata de confiança, a pipeline final usa o campo `grau_ambiguidade`, com três valores possíveis:

- **baixo**: a notícia aponta claramente para um rótulo.
- **medio**: há sinais mistos, mas um rótulo predomina.
- **alto**: o sentimento é incerto, lateral ou contraditório.

Esse campo substitui uma métrica de confiança numérica. A vantagem é interpretativa: em vez de apresentar uma pontuação abstrata, o relatório informa se a própria classificação foi direta ou se dependeu de uma leitura mais ambígua. Isso ajuda a identificar pontos que merecem revisão qualitativa.

4.6 Fase 2: gráficos e tabelas

A segunda fase parte do arquivo bruto de classificações, remove duplicatas por `articleId` e gera a base final:

`tabelas/noticias_classificadas.csv`

Esse CSV possui 852 linhas, ou seja, uma linha por notícia única.

Depois da deduplicação, o procedimento organiza as datas, padroniza os rótulos e calcula variáveis temporais, como mês de publicação. Notícias com data inválida continuam na base final e nas análises gerais, mas não entram nos gráficos mensais, pois não podem ser posicionadas corretamente no tempo.

Em seguida, são calculadas estatísticas agregadas. A contagem geral por sentimento indica a distribuição total da cobertura. As tabelas mensais mostram como a composição dos sentimentos varia ao longo do tempo. A tabela de ambiguidade resume quantas classificações foram diretas ou incertas. A tabela por fonte mostra como os principais veículos aparecem na base e quais sentimentos predominam em cada um.

Também são geradas tabelas agregadas, como:

- `tabelas/sentiment_counts.csv`
- `tabelas/monthly_sentiment_counts.csv`
- `tabelas/monthly_sentiment_percent.csv`
- `tabelas/ambiguity_counts.csv`
- `tabelas/top_sources_sentiment_counts.csv`

Os gráficos finais são salvos em:

`graficos/`

Os gráficos foram escolhidos para responder a perguntas complementares. O gráfico de barras por sentimento mostra a distribuição geral da base. O histograma do score resume a intensidade das classificações. A linha mensal de percentuais mostra mudanças na composição dos sentimentos ao longo do tempo. A área empilhada apresenta a mesma informação de forma acumulada. A linha de volume mensal mostra quando houve maior concentração de notícias. O gráfico de ambiguidade indica a segurança interpretativa das classificações. Por fim, o gráfico por fonte permite observar diferenças entre veículos.

4.7 Fase 3: ranking de eventos

A terceira fase usa a base deduplicada `noticias_classificadas.csv` para gerar:

- `tabelas/eventos_por_noticia.csv`
- `tabelas/eventos_resumo.csv`
- `tabelas/eventos_mais_amados.csv`
- `tabelas/eventos_mais_odiados.csv`

- `tabelas/ranking-eventos.md`

Cada evento é definido pelo campo `evento_chave`, gerado pela LLM. O prompt foi desenhado para evitar agrupamentos excessivamente genéricos. Por exemplo, *Show da Shakira em Copacabana* e *Show da Lady Gaga em Copacabana* devem ser tratados como eventos diferentes, mesmo que ambos envolvam shows em Copacabana.

Nessa etapa, as notícias são agrupadas pelo evento canônico. Para cada grupo, são calculados: número de notícias, número de notícias classificadas com escore válido, média do `sentiment_score`, quantidade de notícias em cada rótulo, proporção de positivas, proporção de negativas, distribuição do grau de ambiguidade e exemplos de títulos associados ao evento.

O ranking principal usa um filtro mínimo de três notícias por evento. Esse filtro evita que um único texto muito positivo ou muito negativo domine o resultado. Depois do filtro, os eventos mais amados são ordenados pela maior média de sentimento; os eventos mais odiados são ordenados pela menor média. Em caso de empate, o procedimento considera a proporção de notícias positivas ou negativas, o peso dos extremos e o número total de notícias do evento.

5 Deduplicação

A base bruta possui 863 linhas. Algumas notícias aparecem mais de uma vez, por isso a análise final remove duplicatas usando o campo `articleId`. Depois dessa etapa, a base final possui 852 notícias únicas.

A deduplicação é aplicada antes das tabelas finais, dos gráficos e do ranking de eventos. Assim, uma notícia repetida não pesa duas vezes nos resultados agregados.

6 Resultados gerais de sentimento

Sentimento	Notícias	Percentual
muito negativo	29	3,40%
negativo	189	22,18%
neutro	18	2,11%
positivo	506	59,39%
muito positivo	4	0,47%
n/a	106	12,44%

Tabela 3: Distribuição de sentimentos na base final deduplicada.

O resultado geral indica predominância de notícias classificadas como positivas. Somando `positivo` e `muito positivo`, há 510 notícias, equivalentes a aproximadamente 59,86% da base final. Já as classes `negativo` e `muito negativo` somam 218 notícias, ou aproximadamente 25,59% da base.

As notícias classificadas como `n/a` representam 12,44%. Esse rótulo foi usado quando a notícia mencionava Segurança Presente de forma lateral ou quando não havia elementos suficientes para avaliar o programa, seus agentes, sua gestão ou evento relacionado.

7 Ambiguidade da classificação

Grau de ambiguidade	Notícias
baixo	799
medio	1
alto	52

Tabela 4: Distribuição do grau de ambiguidade.

A maior parte das classificações foi marcada como de baixa ambiguidade. Isso significa que, segundo o próprio critério solicitado ao modelo, a maioria das notícias apontava claramente para um rótulo de sentimento. O grupo de alta ambiguidade corresponde a textos mais laterais, incertos, contraditórios ou dependentes de interpretação.

8 Rankings de eventos

Os rankings foram calculados apenas para eventos com pelo menos três notícias, a fim de evitar que um único texto isolado dominasse a interpretação. O ranking usa como critério principal a média de `sentiment_score`. Em caso de empate, são considerados a proporção de notícias positivas ou negativas, o peso dos extremos e o número de notícias.

8.1 Eventos mais amados

Evento	N	Score médio	Pos.	Neg.
Criação do comitê permanente de segurança escolar no Rio em 2023	4	1,0000	100,00%	0,00%
Abertura do concurso Segurança Presente RJ em 2025	3	1,0000	100,00%	0,00%
Inauguração da base do Segurança Presente em Irajá em 2025	3	1,0000	100,00%	0,00%
Show da Lady Gaga em Copacabana em 2025	3	1,0000	66,67%	0,00%
Show da Shakira em Copacabana em 2026	4	1,0000	25,00%	0,00%
Transferência do Segurança Presente para a Polícia Militar em 2026	3	0,6667	66,67%	0,00%
Transferência do Segurança Presente para a Polícia Militar	7	0,5000	42,86%	0,00%
Inauguração da base do Segurança Presente em Iguaba Grande em 2026	4	0,0000	50,00%	50,00%
Desaparecimento de José Carlos Simonin em Copacabana em 2026	3	-1,3333	0,00%	100,00%

Tabela 5: Ranking de eventos mais positivamente retratados, considerando eventos com pelo menos três notícias.

O topo do ranking positivo é composto principalmente por eventos administrativos, expansões, concursos, inaugurações e grandes operações de organização urbana em eventos públicos. Isso sugere que a cobertura tende a retratar positivamente o programa quando há anúncio de reforço, expansão, concurso, inauguração ou planejamento de segurança para eventos de grande visibilidade.

8.2 Eventos mais odiados

Evento	N	Score médio	Pos.	Neg.
Desaparecimento de José Carlos Simonin em Copacabana em 2026	3	-1,3333	0,00%	100,00%
Inauguração da base do Segurança Presente em Iguaba Grande em 2026	4	0,0000	50,00%	50,00%
Transferência do Segurança Presente para a Polícia Militar	7	0,5000	42,86%	0,00%
Transferência do Segurança Presente para a Polícia Militar em 2026	3	0,6667	66,67%	0,00%
Criação do comitê permanente de segurança escolar no Rio em 2023	4	1,0000	100,00%	0,00%
Show da Shakira em Copacabana em 2026	4	1,0000	25,00%	0,00%
Abertura do concurso Segurança Presente RJ em 2025	3	1,0000	100,00%	0,00%
Inauguração da base do Segurança Presente em Irajá em 2025	3	1,0000	100,00%	0,00%
Show da Lady Gaga em Copacabana em 2025	3	1,0000	66,67%	0,00%

Tabela 6: Ranking de eventos mais negativamente retratados, considerando eventos com pelo menos três notícias.

O principal evento negativamente retratado foi o desaparecimento de José Carlos Simonin em Copacabana em 2026, com média de -1,3333 e 100% de notícias negativas dentro do grupo. Em seguida aparece a inauguração da base de Iguaba Grande, com média zero, pois o grupo reuniu notícias positivas sobre inauguração e notícias negativas associadas a controvérsias salariais citadas no mesmo conjunto de eventos. Isso mostra uma limitação importante: mesmo com prompt cuidadoso, eventos compostos ou mal agrupados podem misturar pautas próximas e exigir revisão qualitativa.

9 Gráficos produzidos

A pipeline gerou sete gráficos principais:

- `linha_percentual_mensal_sentimentos.png`
- `area_empilhada_percentual_mensal.png`
- `barras_quantidade_por_sentimento.png`

- barras_grau_ambiguidade.png
- histograma_escore_sentimento.png
- linha_volume_mensal_noticias.png
- barras_empilhadas_top_fontes.png

9.1 Distribuição geral




Figura 1: Quantidade de notícias por sentimento.




Figura 2: Histograma do escore de sentimento.

9.2 Evolução temporal




Figura 3: Percentual mensal de notícias por sentimento.




Figura 4: Composição mensal dos sentimentos.




Figura 5: Volume mensal de notícias classificadas.

9.3 Ambiguidade e fontes




Figura 6: Grau de ambiguidade da classificação.




Figura 7: Distribuição de sentimentos por fonte, considerando as principais fontes.

10 Produtos finais gerados

10.1 Tabelas

- tabelas/llm_labels.csv: saída bruta da LLM, com 863 linhas.
- tabelas/noticias_classificadas.csv: base final deduplicada, com 852 notícias.
- tabelas/sentiment_counts.csv: contagem total por sentimento.
- tabelas/monthly_sentiment_counts.csv: contagem mensal por sentimento.
- tabelas/monthly_sentiment_percent.csv: percentual mensal por sentimento.
- tabelas/ambiguity_counts.csv: contagem por grau de ambiguidade.
- tabelas/top_sources_sentiment_counts.csv: sentimentos por fonte.
- tabelas/eventos_por_noticia.csv: evento extraído para cada notícia única.
- tabelas/eventos_resumo.csv: resumo agregado por evento.
- tabelas/eventos_mais_amados.csv: ranking positivo.
- tabelas/eventos_mais_odiados.csv: ranking negativo.
- tabelas/ranking-eventos.md: relatório em Markdown dos rankings.

10.2 Procedimento computacional

O procedimento computacional final foi dividido em módulos lógicos. Primeiro, uma etapa de leitura carrega o JSON de entrada e transforma cada registro bruto em uma observação padronizada, preservando identificador, título, fonte, data, resumo e texto. Em seguida, uma etapa de classificação envia cada notícia ao modelo de linguagem com um prompt único e recebe como resposta um objeto estruturado contendo sentimento, escore, ambiguidade e evento factual.

Depois da classificação, uma etapa de consolidação remove duplicatas por identificador de notícia e gera a base analítica final. Sobre essa base, são calculadas contagens gerais, percentuais mensais, distribuição por fonte e distribuição de ambiguidade. Por fim, uma etapa de agregação agrupa notícias pelo evento canônico retornado pelo modelo, calcula métricas por evento e produz os rankings de eventos mais positivamente e negativamente retratados.

11 Discussão

Os resultados indicam que a cobertura jornalística analisada tende a retratar o Segurança Presente de forma majoritariamente positiva, especialmente em notícias sobre expansão, inauguração de bases, concursos, reforço de policiamento e organização de grandes eventos. Ainda assim, há um conjunto relevante de notícias negativas ou muito negativas, associado a controvérsias, crimes, desaparecimentos, críticas ou problemas institucionais.

O ranking por eventos é uma etapa mais interpretativa do que a contagem geral por sentimento. Ele permite sair da pergunta “quantas notícias foram positivas ou negativas?” e chegar a uma pergunta mais substantiva: “quais acontecimentos concretos concentraram elogios ou críticas?”. Essa mudança é importante porque notícias com palavras semelhantes podem se referir a eventos diferentes, como shows distintos em Copacabana, enquanto notícias com redações distintas podem tratar do mesmo fato administrativo.

12 Limitações

O projeto possui limitações que devem ser consideradas:

- A análise mede a cobertura midiática, não a opinião direta da população.
- A base depende das notícias coletadas e pode não representar todo o universo jornalístico disponível.
- Conteúdos pagos, removidos ou não indexados podem estar ausentes.
- A classificação depende do prompt e do comportamento do modelo usado.
- A identificação de eventos por LLM pode gerar agrupamentos imperfeitos.
- Eventos com poucas notícias podem produzir rankings instáveis; por isso foi usado filtro mínimo de três notícias.
- O campo n/a evita forçar sentimento em notícias laterais, mas também reduz a quantidade de textos efetivamente interpretáveis.

13 Conclusão

O projeto atingiu o objetivo proposto no pré-projeto: construir uma forma automatizada de classificar notícias sobre políticas públicas de segurança usando LLMs. A implementação final foi além da classificação simples de sentimentos, pois também extraiu eventos factuais e permitiu gerar rankings de acontecimentos mais positivamente e negativamente retratados.

A pipeline final é reprodutível, parte de um único JSON de entrada, gera um CSV com classificação por notícia, remove duplicatas nas análises finais, produz gráficos e entrega rankings agregados por evento. O resultado oferece uma leitura sistemática da cobertura midiática sobre o Segurança Presente entre 2016 e 2026, com predominância de notícias positivas, mas também com identificação de eventos críticos e ambíguos que merecem análise qualitativa complementar.